

MENGUNGKAP POLA TERSEMBUNYI DALAM DATA MEDIS



Deteksi Dini Penyakit Jantung Koroner (CHD) Menggunakan Support Vector Machine

Sintesis Algoritma Pembelajaran Mesin untuk Diagnosis Kardiologi Berbasis Data

Referensi: Akhtar et al., 2023 IEEE ICCWAMTIP · Dataset: 918 pasien, 12 atribut

Ancaman Global & Celah Diagnostik

>6 Juta


Angka kematian global per tahun akibat CHD (menurut WHO), dan diproyeksikan terus meningkat hingga 2030.

Interpretasi Manual vs. Volume Data

Elektrokardiogram (EKG) memberikan informasi krusial, namun dokter harus mendeteksi anomali secara manual dari data yang masif.

Dibutuhkan Computer-Aided Diagnosis (CAD) untuk prediksi kejadian iskemik yang akurat, cepat, dan terpersonalisasi.

Mengapa Support Vector Machine (SVM)?



Menaklukkan Dimensi Tinggi


SVM sangat efektif ketika jumlah fitur (dimensi) menantang untuk dianalisis secara manual — ideal untuk 12 atribut klinis.

Menghindari Overfitting

SVM mencari batas keputusan paling optimal dengan margin terlebar, sehingga tidak mudah “menghafal” data latih.


'The Kernel Trick': Mengadaptasi Matematika ke Biologi

Karena data medis tidak selalu dapat dipisahkan secara linear, penelitian ini menguji empat fungsi kernel untuk menemukan harmoni terbaik antara data dan diagnosis:



Alur Kerja Sistem

BARU



Train-Test Split (80/20) ditambahkan sebagai baseline sebelum validasi silang — membagi data satu kali untuk uji cepat performa awal model.

Membedah Data Pasien: Dari Kebisingan Menjadi Sinyal

Kunci akurasi mesin terletak pada kurasi data. Dataset open-source 918 pasien disaring secara komputasi menjadi fitur paling relevan.

76

Atribut Klinis Mentah



12

Atribut Super-Relevan

12 Atribut Terpilih

- Usia
- Jenis Kelamin
- Nyeri Dada
- Tekanan Darah
- Kolesterol
- Gula Darah Puasa
- ECG Istirahat
- Detak Jantung
- Angina Olahraga
- Oldpeak
- ST Slope
- Subjek Target


Reduksi dimensi 76 → 12 atribut adalah kunci di balik tingkat deteksi yang tinggi: meminimalkan kebisingan data klinis.

Pemetaan Fitur: Visualisasi Korelasi Fisiologis

Heat map menunjukkan hubungan antar fitur yang dipilih secara komputasi. Pola interdependensi yang kuat inilah yang menjadi dasar pengambilan keputusan oleh algoritma SVM.

Zona Korelasi Tinggi

Pola yang sering terlewatkan oleh interpretasi visual manusia, namun mudah ditangkap oleh arsitektur komputasi.



Mendefinisikan Kesuksesan Medis

Confusion Matrix

True Positive (TP)

False Positive (FP)

False Negative (FN)

True Negative (TN)

Akurasi

Persentase total prediksi yang benar: $(TN+TP) / \text{Keseluruhan}$.

AUC (Area Under Curve)

Kapabilitas membedakan kelas. Mendekati 1.0 = pemisahan sempurna.


Sensitivitas (Krusial)

Kemampuan mendeteksi kasus positif: $TP / (TP+FN)$.

Dalam kardiologi, meminimalkan False Negative (memulangkan pasien berisiko) adalah prioritas mutlak.

Validasi Train-Test Split (80/20)

Pengujian baseline: model dilatih pada 734 pasien (80%) dan diuji pada 184 pasien (20%) yang belum pernah dilihat.



RBF Unggul


Akurasi 89.1% & AUC 92.9% — tertinggi pada split tunggal ini.

Perlu Validasi

Hasil satu split bisa kebetulan — divalidasi lebih lanjut lewat CV & LOO.

Validasi Silang 5-Fold

Pengujian lebih objektif: data dibagi 5 bagian, model diuji bergiliran lalu dirata-rata.



Linear


Akurasi 85.6% · Sensitivitas 85.6%.

Sigmoid

Akurasi 86.4% · Sensitivitas 86.4% —
mulai unggul.

Validasi Leave-One-Out

Pengujian paling ketat membuktikan ketahanan model, memastikan tidak terjadi overfitting.



Puncak AUC

Model Linear mencapai 93.60% — pemisahan kelas terbaik.

Puncak Akurasi

Model Sigmoid mencapai 87.80% — diagnosis terbaik.

Matriks Perbandingan Diagnostik

Kernel	Akurasi (LOO)	AUC (LOO)	Sensitivitas (LOO)
Linear	87.7%	93.6% ▲	87.7%
Polynomial	81.6%	89.9%	81.6%
RBF	83.3%	89.4%	83.3%
Sigmoid	87.8% ▲	93.5%	87.8% ▲

Sigmoid — Pemenang Akurasi (87.8%) & Sensitivitas: kapasitas terbaik untuk identifikasi pasien positif.

Linear — Pemenang AUC (93.6%): paling andal membedakan pasien CHD vs sehat. RBF & Polynomial solid (>81%) namun kurang optimal.

Mengapa Linear & Sigmoid Unggul?

“

Kinerja superior model Linear & Sigmoid membuktikan prinsip fundamental: dengan reduksi fitur komputasi yang tepat, pola penyakit jantung dapat diurai dengan sangat jelas — sehingga model non-linear yang kompleks (RBF) justru tidak selalu diperlukan.

Hasil pada satu split tunggal (RBF terbaik) berbeda dengan hasil validasi menyeluruh — inilah bukti nyata pentingnya Cross Validation.

Masa Depan Kardiologi Berbasis Data

Presisi

Algoritma SVM dengan reduksi fitur optimal mampu memberikan deteksi dini CHD dengan akurasi & sensitivitas tinggi.

Validasi Berlapis

Train-Test Split, 5-Fold CV, dan Leave-One-Out memastikan hasil model stabil dan tidak overfitting.

Pemberdayaan

Teknologi ini bukan pengganti, melainkan instrumen mutakhir yang memberdayakan tenaga medis dengan wawasan data.

Mengubah raw data menjadi keselamatan pasien.